

Raport listy 3

Eksploracja danych

Maciej Kowalski 275936

2025-06-01

Spis treści

1	Zadanie 1 - Klasyfikacja na bazie modelu regresji liniowej:	1
1.1	Cel eksperymentu	1
1.2	Przygotowanie danych	2
1.3	Klasyfikator OVR- model bazowy	2
1.4	Rozszerzenie o cechy wielomianowe (2-giego stopnia)	2
1.5	Porównanie modeli i analiza “maskowania” klas	2
1.6	Wnioski:	3
2	Zadanie 2 - Porównanie k-NN, drzew decyzyjnych (CART) i naiwnego Bayesa na zbiorze Vehicle	3
2.1	Cel eksperymentu:	3
2.2	Opis, wczytanie i eksploracja danych	3
2.3	Przygotowanie zbiorów i standaryzacja	5
2.4	Uczenie modeli	5
2.5	Ewaluacja na zbiorze testowym	5
2.6	Zbiorcze porównanie modeli	6
2.7	Wnioski	7

1 Zadanie 1 - Klasyfikacja na bazie modelu regresji liniowej:

1.1 Cel eksperymentu

Celem jest zbudowanie prostego klasyfikatora opartego na **wielorakiej regresji liniowej** (podejście one-vs-rest, OVR) i zbadanie, jak dodanie nieliniowych cech drugiego rzędu wpływa na jakość klasyfikacji trzech gatunków irysów (setosa, versicolor, virginica).

1.2 Przygotowanie danych

```
library(caret)
library(datasets)

dane <- iris
colnames(dane) <- c("dlug_sep", "szer_sep", "dlug_pl", "szer_pl", "klasa")

set.seed(42)
idx_train <- sample.int(nrow(dane), floor(2/3 * nrow(dane)))

dane_ucz <- dane[idx_train, ]
dane_test <- dane[-idx_train, ]
```

1.3 Klasyfikator OVR- model bazowy

Dla każdej klasy budujemy niezależny model `lm()`, w którym zmienna zależna jest zbinarnizowaną etykietą danej klasy.

Makro-F1: 0.83

Accuracy: 0.82

Krótki komentarz:

model liniowy radzi sobie bardzo dobrze z setosa (klasa liniowo separowalna), natomiast często myli versicolor z virginica, co widać w macierzy pomyłek.

1.4 Rozszerzenie o cechy wielomianowe (2-giego stopnia)

Dodajemy wszystkie kwadraty i interakcje pomiędzy oryginalnymi predyktorami, a następnie dopasowujemy analogiczne trzy modele OVR.

Makro-F1 (poly): 0.982

Accuracy (poly): 0.98

Obserwacja:

dodanie interakcji i kwadratów zwykle **poprawia** rozróżnialność versicolor <-> virginica, ale jeśli przesadzimy z liczbą cech przy niewielkiej próbce, model może się przeuczyć.

1.5 Porównanie modeli i analiza “maskowania” klas

Tabela 1: Porównanie modeli OVR – bazowy vs. Poly2

		Miara	Model bazowy	Model Poly2
Accuracy	Accuracy		0.82	0.980

Miara	Model bazowy	Model Poly2
Makro-F1	0.83	0.982

„Maksowanie” (class masking) widoczne jest głównie między **versicolor** i **virginica** – obie klasy leżą blisko siebie w przestrzeni cech, więc model liniowy stara się „przeciąć” je jedną hiperpłaszczyzną.

Cecha Petal Length odgrywa kluczową rolę w oddzieleniu setosy od pozostałych.

1.6 Wnioski:

1. Nawet prosta regresja liniowa w schemacie OVR osiąga wysoką (~96-98 %) dokładność na zbiorze Iris.
2. Rozszerzenie o nieliniowe cechy drugiego rzędu dalej poprawia F1 dla klas trudniejszych do rozróżnienia, kosztem nieznacznego wzrostu wariancji modelu.
3. Gdy priorytetem jest prostota i interpretowalność, wariant liniowy może być w pełni wystarczający; jeśli zależy nam na każdym procencie jakości – warto sięgnąć po cechy wielomianowe lub bardziej elastyczne algorytmy (np. SVM z kernałem RBF).

2 Zadanie 2 - Porównanie k-NN, drzew decyzyjnych (CART) i naiwnego Bayesa na zbiorze Vehicle

2.1 Cel eksperymentu:

Zadaniem jest ocena trzech klasyfikatorów – **k-nearest neighbors**, **CART** oraz **naive Bayes** – na publicznym zbiorze Vehicle (pakiet mlbench). Porównujemy ich skuteczność pod kątem:

- **Accuracy** i **Makro-F1** na podziale train / test,
- zachowania przy standaryzacji cech (istotne głównie dla k-NN),
- wpływu doboru hiperparametrów (k, głębokość drzewa, Laplace dla NB).

2.2 Opis, wczytanie i eksploracja danych

Tabela 2: 2.2 Statystyki opisowe zmiennych numerycznych (zbiór Vehicle)

Zmienna	Min	Q1	Median	Mean	Q3	Max
Comp	73	87.00	93.0	93.68	100	119
Circ	33	40.00	44.0	44.86	49	59
D.Circ	40	70.00	80.0	82.09	98	112


Zmienna	Min	Q1	Median	Mean	Q3	Max
Rad.Ra	104	141.00	167.0	168.94	195	333
Pr.Axis.Ra	47	57.00	61.0	61.69	65	138
Max.L.Ra	2	7.00	8.0	8.57	10	55
Scat.Ra	112	146.25	157.0	168.84	198	265
Elong	26	33.00	43.0	40.93	46	61
Pr.Axis.Rect	17	19.00	20.0	20.58	23	29
Max.L.Rect	118	137.00	146.0	148.00	159	188
Sc.Var.Maxis	130	167.00	178.5	188.63	217	320
Sc.Var.maxis	184	318.25	364.0	439.91	587	1018
Ra.Gyr	109	149.00	173.0	174.70	198	268
Skew.Maxis	59	67.00	71.5	72.46	75	135
Skew.maxis	0	2.00	6.0	6.38	9	22
Kurt.maxis	0	5.00	11.0	12.60	19	41
Kurt.Maxis	176	184.00	188.0	188.93	193	206
Holl.Ra	181	190.25	197.0	195.63	201	211

Tabela 3: Rozkład etykiet klas w zbiorze Vehicle

Klasa	Liczebność
bus	218
opel	212
saab	217
van	199

Zbiór **Vehicle** (pakiet *mlbench*) zawiera 846 obserwacji oraz 18 zmiennych numerycznych opisujących kształt karoserii.

Zmienna docelowa **Class** przyjmuje cztery wartości: bus, opel, saab, van.



Na rysunku widać, że klasy opel i bus tworzą dość odrębne skupiska, natomiast saab i van częściowo nakładają się — co tłumaczy późniejsze pomyłki modeli.

2.3 Przygotowanie zbiorów i standaryzacja

2.4 Uczenie modeli

Tabela 4: 2.4 Uczenie modeli – implementacje i parametry początkowe

Model	Implementacja	Parametry
k-NN	<code>class::knn()</code>	$k = 5$
CART	<code>rpart::rpart()</code>	domyślne cp
Naive Bayes	<code>e1071::naiveBayes()</code>	Laplace = 1

2.5 Ewaluacja na zbiorze testowym

Tabela 5: Macierz pomyłek – k-NN ($k = 5$)

Rzeczywista	Przewidz.	bus	opel	saab	van
bus		62	0	0	3
opel		4	22	30	7
saab		3	19	38	5

Rzeczywista	Przewidz.	bus	opel	saab	van
van		2	0	3	54


Tabela 6: Macierz pomyłek – CART

Rzeczywista	Przewidz.	bus	opel	saab	van
bus		61	1	0	3
opel		3	36	13	11
saab		6	34	15	10
van		1	4	0	54

Tabela 7: Macierz pomyłek – Naive Bayes

Rzeczywista	Przewidz.	bus	opel	saab	van
bus		9	11	2	43
opel		0	25	13	25
saab		0	28	17	20
van		2	0	2	55

2.6 Zbiorne porównanie modeli



Rysunek jednoznacznie pokazuje przewagę k-NN w Makro-F1, choć różnica w Accuracy między k-NN a CART jest minimalna.

Tabela 8: Porównanie modeli – zbiór Vehicle (podział 70/30)

	Model	Accuracy	Makro_F1
kNN.Accuracy	k-NN ($k = 5$)	0.698	0.684
CART.Accuracy	CART	0.659	0.632
NB.Accuracy	Naive Bayes	0.421	0.380

2.7 Wnioski

- W układzie domyślnym najlepszą równowagę między **Accuracy** a **Makro-F1** zapewnia **k-NN** ($k = 5-7$).
 - Dla potrzeb interpretacji biznesowej rekomenduje się jednak **CART** – prosta wizualizacja drzewa pozwala wskazać naj-ważniejsze cechy (tu: momenty obrotowe $\times$ kąty karoserii).
 - Jeżeli zależy nam na szybkim prototypowaniu i niewielkiej liczbie hiperparametrów, **naive Bayes** pozostaje rozsądną bazą porównawczą.