

Sprawozdanie 2

Analiza Przeżycia

Mateusz Wizner 277508, Maciej Kowalski 275936

16 December 2025

Spis treści

Wstęp	1
Lista 5	2
Zadanie 1: Estymatory Kaplana-Meiera i Fleminga-Harringtona	2
Wnioski:	3
Zadanie 2: Estymacja z korektą ogona (metoda BHK)	4
Zadanie 3: Asymptotyczna normalność estymatora	5
Wnioski:	7
Lista 6	7
Zadanie 1: Program do estymacji średniego czasu życia (korekta BHK)	7
Zadanie 2: Oszacowanie średnich czasów do remisji (Lek A vs Lek B)	9
Wnioski:	9
Lista 7	9
Zadanie 1: Funkcja do obliczania przedziałów ufności dla średniej (RMST)	9
Zadanie 2: Analiza danych Mayo Clinic (Rak jajnika)	11
Wnioski:	11
Lista 8	12
Zadanie 1: Weryfikacja hipotezy o równości rozkładów.	12
Wnioski:	13
Zadanie 2: Analiza graficzna (Krzywe KM i Funkcje Wagowe)	13
Wnioski:	14

Wstęp

Niniejszy raport obejmuje rozwiązania zadań z List 5, 6, 7 oraz 8. Tematyka dotyczy estymacji funkcji przeżycia metodami nieparametrycznymi (estymatory Kaplana-Meiera i Fle-

minga-Harringtona), estymacji średniego czasu życia z korektą ogona (metoda Browna-Hollander-Kowara) oraz testowania hipotez o równości rozkładów czasu życia (test Log-Rank i pochodne).

Dla zachowania spójności, w zadaniach wykorzystano dane pacjentów z Listy 2 (Lek A i B) oraz dane z badania Mayo Clinic (Grupa 1 i 2).

Lista 5

Zadanie 1: Estymatory Kaplana-Meiera i Fleminga-Harringtona

Celem zadania jest porównanie estymatorów funkcji przeżycia uzyskanych metodą Kaplana-Meiera oraz Fleminga-Harringtona dla dwóch grup pacjentów leczonych lekiem A i lekiem B.

Poniżej przedstawiono kod wczytujący dane oraz wyznaczający oba estymatory.

```
czas_A_event <- c(0.033, 0.087, 0.088, 0.244, 0.278,
                  0.408, 0.588, 0.641, 0.907, 0.942)
czas_A <- c(czas_A_event, rep(1.0, 10))
status_A <- c(rep(1, 10), rep(0, 10)) # 1=zdalenie, 0=cenzura

czas_B_event <- c(0.038, 0.122, 0.203, 0.245, 0.305,
                  0.342, 0.430, 0.445, 0.638, 0.691)
czas_B <- c(czas_B_event, rep(1.0, 10))
status_B <- c(rep(1, 10), rep(0, 10))


surv_obj_A <- Surv(czas_A, status_A)
surv_obj_B <- Surv(czas_B, status_B)

fit_km_A <- survfit(surv_obj_A ~ 1, type = "kaplan-meier")
fit_km_B <- survfit(surv_obj_B ~ 1, type = "kaplan-meier")


fit_fh_A <- survfit(surv_obj_A ~ 1, type = "fleming-harrington")
fit_fh_B <- survfit(surv_obj_B ~ 1, type = "fleming-harrington")
```

Następnie wygenerowano wykresy porównawcze dla obu estymatorów.

Estymator Kaplana–Meiera



Estymator Fleminga–Harringtona



Wnioski:

Analizując powyższe wykresy, można zauważyć, że przebieg krzywych przeżycia dla obu leków jest zbliżony. Estymator Fleminga-Harringtona daje bardzo podobne rezultaty do estymatora Kaplana-Meiera. W grupie przyjmującej Lek B obserwuje się nieco szybszy spadek funkcji

przeżycia w początkowym okresie, co może sugerować szybsze występowanie remisji w tej grupie.

Zadanie 2: Estymacja z korektą ogona (metoda BHK)

W przypadku danych cenzurowanych, gdy ostatnia obserwacja nie jest zdarzeniem, estymator Kaplana-Meiera nie osiąga zera. W celu oszacowania dalszego przebiegu funkcji przeżycia zastosowano metodę Browna, Hollandera i Kowara (BHK), która dopasowuje ogon wykładniczy.

Poniżej przedstawiono funkcję realizującą tę metodę oraz przygotowanie danych do wykresu.

```
get_bhk_data <- function(time, status, group_name, extension_factor = 2.0) {
  fit <- survfit(Surv(time, status) ~ 1)

  km_data <- data.frame(
    time = c(0, fit$time),
    surv = c(1, fit$surv),
    type = "Kaplan-Meier"
  )

  t_last <- max(km_data$time)
  s_last <- km_data$surv[nrow(km_data)]

  if (s_last > 0) {
    t_tail <- seq(from = t_last, to = t_last * extension_factor, length.out = 100)


    s_tail_vals <- exp((log(s_last) / t_last) * t_tail)

    tail_data <- data.frame(time = t_tail, surv = s_tail_vals, type = "Ogon BHK")
    full_data <- rbind(km_data, tail_data)
  } else {
    full_data <- km_data
  }

  full_data$group <- group_name
  return(full_data)
}

df_bhk_A <- get_bhk_data(czas_A, status_A, "Lek A")
df_bhk_B <- get_bhk_data(czas_B, status_B, "Lek B")
plot_data <- rbind(df_bhk_A, df_bhk_B)
```

Wykres estymatorów z dorysowanymi ogonami wykładniczymi:



Zastosowanie korekty BHK pozwala na prognozowanie prawdopodobieństwa przeżycia (braku remisji) dla czasów przekraczających czas trwania badania ($t > 1.0$).

Zadanie 3: Asymptotyczna normalność estymatora

Przeprowadzono symulację Monte Carlo ($M = 1000$ powtórzeń) w celu zbadania rozkładu estymatora funkcji przeżycia w dwóch punktach: t_0 (wewnątrz zakresu danych) oraz $2t_0$ (w obszarze ekstrapolowanym metodą BHK). Dane generowano z uogólnionego rozkładu wykładniczego (Generalized Exponential - GE).

Poniżej zamieszczono kod przeprowadzający symulację dla licznosci próby $n \in \{30, 50, 100\}$.

```
qge <- function(u, a, l) {
  (-log(1 - u^(1/a))) / l
}

generuj_dane_Typ_I <- function(n, t0, a, l) {
  u <- runif(n)
  x <- qge(u, a, l)
  data.frame(time = pmin(x, t0), status = as.integer(x <= t0))
}

alpha_param <- 2.0
lambda_param <- 1.0

set.seed(123)
```

```

duza_proba <- qge(runif(50000), alpha_param, lambda_param)
t0_val <- mean(duza_proba)

M <- 1000
N_values <- c(30, 50, 100)
wyniki_symulacji <- data.frame()

set.seed(42)

for (n in N_values) {
  est_t0 <- numeric(M)
  est_2t0 <- numeric(M)

  for (i in 1:M) {
    df <- generuj_dane_Typ_I(n, t0_val, alpha_param, lambda_param)
    fit <- survfit(Surv(time, status) ~ 1, data = df)


    sum_fit <- summary(fit, times = t0_val, extend = TRUE)
    val_S_t0 <- sum_fit$surv
    if(length(val_S_t0) == 0) val_S_t0 <- 0
    est_t0[i] <- val_S_t0

    if (val_S_t0 > 0) {
      val_S_2t0 <- exp((log(val_S_t0) / t0_val) * (2 * t0_val))
    } else {
      val_S_2t0 <- 0
    }
    est_2t0[i] <- val_S_2t0
  }

  temp_res <- data.frame(
    N = as.factor(n),
    Punkt = rep(c("t0", "2t0"), each = M),
    Wartosc = c(est_t0, est_2t0)
  )
  wyniki_symulacji <- rbind(wyniki_symulacji, temp_res)
}

```

Wyniki symulacji przedstawiono w formie histogramów gęstości.



Wnioski:

Na podstawie otrzymanych histogramów można zauważyć, że:

- W punkcie t_0 (wewnątrz zakresu danych), wraz ze wzrostem liczebności próby ($n = 100$), rozkład estymatora coraz bardziej przypomina rozkład normalny. Jest to zgodne z teorią o asymptotycznej normalności estymatora Kaplana-Meiera.
- W punkcie $2t_0$ (obszar ekstrapolowany), rozkłady wykazują większą skośność, szczególnie dla małych prób ($n = 30$). Niemniej jednak, dla większych liczebności próby również widać tendencję do symetryzacji rozkładu.

Lista 6

Zadanie 1: Program do estymacji średniego czasu życia (korekta BHK)

W standardowym estymatorze Kaplana-Meiera, jeśli ostatnia obserwacja jest cenzurowana, krzywa przeżycia nie opada do zera. Powoduje to, że średni czas życia (definiowany jako pole pod krzywą $S(t)$) jest nieokreślony (całka rozbieżna). Rozwiązaniem tego problemu jest metoda Browna, Hollandera i Kowara (BHK), która polega na dopasowaniu wykładniczego „ogona” do ostatniego punktu estymatora, co pozwala na obliczenie skończonej całki.

Poniżej przedstawiono funkcję `estimate_mean_BHK`, która implementuje ten mechanizm. Funkcja oblicza średni czas przeżycia zarówno dla estymatora Kaplana-Meiera, jak i Flemin-ga-Harringtona.

```

estimate_mean_BHK <- function(time, status) {

  data <- data.frame(time = time, status = status)
  data <- data[order(data$time), ]
  unique_times <- unique(data$time)

  n_risk <- numeric(length(unique_times))
  n_event <- numeric(length(unique_times))

  for (i in 1:length(unique_times)) {
    t <- unique_times[i]
    n_risk[i] <- sum(data$time >= t)
    n_event[i] <- sum(data$time == t & data$status == 1)
  }

  term_km <- (n_risk - n_event) / n_risk
  term_km[is.nan(term_km)] <- 0
  S_km <- cumprod(term_km)

  H_na <- cumsum(n_event / n_risk)
  S_fh <- exp(-H_na)

  calculate_mean_with_tail <- function(S_values, times) {
    t_last <- max(times)
    S_last <- tail(S_values, 1)

    times_ext <- c(0, times)
    S_ext <- c(1, S_values)
    intervals <- diff(times_ext)

    area_observed <- sum(S_ext[1:length(intervals)] * intervals)

    tail_area <- 0
    if (S_last > 0 && S_last < 1) {
      tail_area <- (-t_last * S_last) / log(S_last)
    }

    return(area_observed + tail_area)
  }

  mean_km <- calculate_mean_with_tail(S_km, unique_times)
  mean_fh <- calculate_mean_with_tail(S_fh, unique_times)

  return(list(Mean_KM = mean_km, Mean_FH = mean_fh))
}

```


}

Zadanie 2: Oszacowanie średnich czasów do remisji (Lek A vs Lek B)

Korzystając z napisanej funkcji, oszacowano średnie czasy do remisji choroby dla pacjentów leczonych lekiem A oraz lekiem B (dane z Listy 2, zadanie 3).

Wyniki przedstawiono w poniższej tabeli:

Tabela 1: Oszacowane średnie czasy do remisji z korektą BHK

Estymator	Lek A [lata]	Lek B [lata]	Różnica (A-B)
Kaplan-Meier	1.4321	1.3943	0.0378
Fleming-Harrington	1.4840	1.4471	0.0369

Wnioski:

Oszacowany średni czas do remisji wynosi:

- Dla **Leku A**: około 1.4321 roku (według estymatora Kaplana-Meiera).
- Dla **Leku B**: około 1.3943 roku.

Różnica między grupami wynosi w przybliżeniu 0.0378. Warto zauważyć, że wyniki uzyskane przy użyciu estymatora Fleminga-Harringtona są niemal identyczne (różnice pojawiają się dopiero na trzecim miejscu po przecinku), co świadczy o stabilności oszacowania.

Mimo że na wykresach funkcji przeżycia (Lista 5) krzywa dla Leku B opadała szybciej w początkowej fazie (co sugerowało szybsze remisje u części pacjentów), uwzględnienie „ogona” (czyli pacjentów, u których remisja nie nastąpiła w trakcie rocznej obserwacji) pokazuje, że ogólny średni czas oczekiwania na remisję jest w obu grupach porównywalny, z lekką przewagą (krótszym czasem) dla Leku B.

Lista 7

Zadanie 1: Funkcja do obliczania przedziałów ufności dla średniej (RMST)

W analizie przeżycia, ze względu na obecność danych cenzurowanych, klasyczna średnia arytmetyczna jest obciążona. Alternatywą jest szacowanie średniego czasu przeżycia ograniczonego do pewnego punktu czasowego τ (Restricted Mean Survival Time – RMST). Estymator ten definiuje się jako pole pod krzywą Kaplana-Meiera w przedziale $[0, \tau]$.

Poniżej zaimplementowano funkcję `ObliczPrzedzialSredniej`, która:

- Wyznacza estymator Kaplana-Meiera.
- Oblicza estymator punktowy $\hat{\mu}_\tau$ jako całkę z funkcji przeżycia.
- Oblicza wariancję estymatora zgodnie ze wzorem (16) z Wykładu 6.
- Wyznacza granice przedziału ufności przy zadanym poziomie ufności $1 - \alpha$.

```
ObliczPrzedzialSredniej <- function(time, status, alpha = 0.05, tau) {

  km_fit <- survfit(Surv(time, status) ~ 1)

  t_i <- km_fit$time
  r_i <- km_fit$n.risk
  d_i <- km_fit$n.event
  S_i <- km_fit$surv

  t_all <- c(0, t_i)
  S_all <- c(1, S_i)

  relevant_indices <- which(t_all < tau)
  t_calc <- t_all[relevant_indices]
  S_calc <- S_all[relevant_indices]

  t_points <- c(t_calc, tau)

  dt <- diff(t_points)

  mu_hat <- sum(S_calc * dt)

  var_sum <- 0

  event_indices <- which(d_i > 0 & t_i < tau)

  for (idx in event_indices) {
    ti_current <- t_i[idx]

    sub_indices <- which(t_all >= ti_current & t_all < tau)

    if(length(sub_indices) > 0) {
      t_sub <- c(t_all[sub_indices], tau)
      S_sub <- S_all[sub_indices]
      dt_sub <- diff(t_sub)
      area_tail <- sum(S_sub * dt_sub)
    } else {
      area_tail <- 0
    }
  }
}
```

```

    }
    term <- (area_tail^2) * (d_i[idx] / (r_i[idx] * (r_i[idx] - d_i[idx])))

    if (!is.na(term) && is.finite(term)) {
      var_sum <- var_sum + term
    }
  }

  V_hat <- var_sum

  z_score <- qnorm(1 - alpha/2)
  se <- sqrt(V_hat)

  lower <- mu_hat - z_score * se
  upper <- mu_hat + z_score * se

  return(list(
    tau = tau,
    mu = mu_hat,
    se = se,
    lower = lower,
    upper = upper
  ))
}

```

Zadanie 2: Analiza danych Mayo Clinic (Rak jajnika)

Celem zadania jest porównanie średniego czasu do progresji choroby w dwóch grupach pacjentek z rakiem jajnika (dane z Mayo Clinic):

- **Grupa 1:** Niski stopień zaawansowania (Stadium II).
- **Grupa 2:** Wysoki stopień zaawansowania (Stadium IIIA).

Dla porównania wybrano dwie wartości τ :

$\tau_1 = 462$ dni (czas ostatniego zdarzenia w Grupie 1 przed serią cenzurowań).

$\tau_2 = 1500$ dni (wartość obejmująca cały horyzont czasowy badania).

Wnioski:

Analizując horyzont czasowy ograniczony do $\tau = 462$ dni:

- Średni czas przeżycia dla grupy z **niskim stopniem** zaawansowania wynosi około 361.07 dni.
- Dla grupy z **wysokim stopniem** wynosi on około 322.38 dni.

Przedziały ufności dla obu grup (284 - 439 vs 270 - 374) nakładają się, co sugeruje brak istotnych statystycznie różnic w średnim czasie do progresji w tym krótszym okresie.

Natomiast dla dłuższego horyzontu $\tau = 1500$ dni:

- Różnica w średnich staje się wyraźniejsza: 937.73 dni (Niski stopień) w porównaniu do 413.2 dni (Wysoki stopień).
- Pacjentki z niższym stopniem zaawansowania choroby mają prognozowany dłuższy czas wolny od progresji.
- Należy jednak zauważyć, że przy dłuższym horyzoncie czasowym błąd standardowy (SE) rośnie (szczególnie w grupie 1: $SE = 177.46$), co wynika z mniejszej liczby pacjentów pozostających w obserwowanym ryzyku (duża liczba cenzurowań). Mimo dużej różnicy punktowej, przedziały ufności nadal mogą się stykać lub nakładać, co wymagałoby weryfikacji testem statystycznym (np. log-rank) w celu potwierdzenia istotności.

Tabela 2: Średni czas do progresji choroby (RMST) i przedziały ufności 95%

Grupa	Tau [dni]	Średnia [dni]	Błąd Std.	95% CI	95% CI
				Dolny	Górny
Niski st. (II)	462	361.07	39.54	283.57	438.56
Wysoki st. (IIIA)	462	322.38	26.53	270.37	374.39
Niski st. (II)	1500	937.73	177.46	589.91	1285.56
Wysoki st. (IIIA)	1500	413.20	92.08	232.73	593.67

Lista 8

Zadanie 1: Weryfikacja hipotezy o równości rozkładów.

Celem zadania jest weryfikacja hipotezy zerowej $H_0 : S_1(t) = S_2(t)$, mówiącej o jednakowym rozkładzie czasu do progresji choroby w obu grupach pacjentek (dane z Mayo Clinic).

Do weryfikacji wykorzystano cztery testy, różniące się przyjętą funkcją wagową $W(t)$:

- Test Log-rank ($W(t) = 1$) – najbardziej efektywny przy założeniu proporcjonalnych hazardów.
- Test Gehana-Breslowa ($W(t) = n(t)$) – przywiązuje większą wagę do wczesnych zdarzeń (gdy liczba osób w ryzyku jest duża).
- Test Tarone-Ware ($W(t) = \sqrt{n(t)}$) – waga pośrednia między Log-rank a Gehanem.
- Test Peto-Peto ($W(t) = \tilde{S}(t)$) – waga oparta na estymatorze funkcji przeżycia, odporna na niestabilność estymacji w ogonach.

Obliczenia wykonano przy użyciu pakietu coin, który umożliwia wybór typu testu.

Tabela 3: Porównanie p-wartości dla różnych testów rangowych

Test	Waga	p_value
Log-rank	1	0.0194
Gehan-Breslow	$n(t)$	0.1336
Tarone-Ware	$\sqrt{n(t)}$	0.0552
Peto-Peto	$S(t)$	0.0978

Wnioski:


Wartość p dla testu Log-rank wynosi 0.0194, co jest powyżej poziomu istotności $\alpha = 0.05$. Oznacza to brak podstaw do odrzucenia hipotezy zerowej przy użyciu tego testu.

Testy ważące wczesne zdarzenia, takie jak Gehan-Breslow ($p = 0.1336$) czy Tarone-Ware ($p = 0.0552$), dają niższe wartości p, sugerując, że różnice między grupami mogą być istotne we wczesnej fazie badania, czego test Log-rank “nie widzi” ze względu na późniejsze zbieganie się krzywych.

Zadanie 2: Analiza graficzna (Krzywe KM i Funkcje Wagowe)

Aby zrozumieć przyczyny różnic w p-wartościach, sporządzono wykresy estymatorów Kaplana-Meiera oraz przebiegu znormalizowanych funkcji wagowych dla poszczególnych testów.


A. Krzywe przeżycia



Na powyższym wykresie widać, że krzywe przecinają się na początku, a rozchodzą dopiero później. Poniżej przedstawiono, jak różne testy “ważą” te okresy.

B. Funkcje wagowe testów

Który moment badania jest ważniejszy dla danego testu?



Wnioski:

Krzywe przeżycia (Wykres A): Widać wyraźnie, że w pierwszej połowie badania (do ok. 400 dnia) linie się przeplatają. Dopiero później niebieska linia (Grupa 2) spada niżej.

Wagi testów (Wykres B):

Test **Log-Rank** (czerwona linia) traktuje cały czas trwania badania tak samo (waga = 1). Dlatego uwzględnia końcową różnicę, ale “gubi” ją przez brak różnic na początku.

Test **Gehana** (zielona linia) nadaje ogromną wagę początkowi badania (gdy jest dużo pacjentów), a końcówkę prawie ignoruje (waga bliska 0). Skupia się na tym etapie, gdzie krzywe się przecinają, co prowadzi do innego wyniku p-value.

To rozbieżne zachowanie testów jest typowe dla sytuacji, gdy hazardy nie są proporcjonalne (krzywe się krzyżują)