

Raport listy 1

Eksploracja danych

Maciej Kowalski 275936

2025-04-04

Spis treści

1 Opis zagadnienia:

Celem niniejszej analizy jest zastosowanie metod eksploracyjnej analizy danych do zbioru informacji o klientach firmy telekomunikacyjnej, udostępnionego na platformie Kaggle. Zbiór zawiera dane dotyczące m.in. cech demograficznych klientów, rodzaju używanych usług oraz informacji o tym, czy klient zrezygnował z usług firmy (zmienna Churn). Analiza ma na celu:

- wstępne zapoznanie się z danymi,
- przeprowadzenie opisu cech jakościowych i ilościowych,
- zbadanie zależności między zmiennymi,
- porównanie grupy klientów, którzy zrezygnowali z usług, oraz tych, którzy pozostali,
- sformułowanie wniosków oraz próba identyfikacji czynników wpływających na decyzję klienta o odejściu.

#Opis przeprowadzonych analiz:

Analiza obejmowała kilka etapów:

- **Wstępne przygotowanie danych:**

sprawdzenie rozmiaru zbioru, struktury danych, typów zmiennych oraz brakujących i nietypowych wartości. Usunięto zmienną identyfikacyjną customerID oraz wiersze z błędnie zakodowanymi wartościami (np. TotalCharges = “”).

- **Analiza opisowa cech:**

dla zmiennych ilościowych (np. tenure, MonthlyCharges, TotalCharges) wyznaczono podstawowe miary położenia i rozproszenia (średnia, mediana, odchylenie standardowe, kwartyle). Dla zmiennych jakościowych (np. gender, Contract, InternetService) policzono liczebności kategorii i wykonano wizualizacje.

- **Analiza graficzna:**

wykorzystano szereg technik graficznych w języku R (głównie za pomocą ggplot2) — histogramy, wykresy pudełkowe (boxploty), wykresy słupkowe i rozrzutu — w celu zilustrowania rozkładów zmiennych oraz zależności między nimi. Część wykresów wykonano z podziałem na grupy Churn == “Yes” i Churn == “No”.

- **Porównania między grupami:**

Dane zostały rozdzielone na dwie grupy — klientów, którzy odeszli oraz tych, którzy pozostali. Następnie porównano cechy w obu grupach, zarówno jakościowe, jak i ilościowe, aby zidentyfikować potencjalne różnice.

W analizie zastosowano metody statystyki opisowej oraz eksploracji danych dla zbioru empirycznego (rzeczywistego). Wielkość próby po przetworzeniu danych wynosiła 7032 obserwacje (po usunięciu braków).

Wykorzystano następujące narzędzia i metody analizy:

- metody graficzne: histogramy, wykresy pudełkowe, wykresy słupkowe, wykresy rozrzutu
- statystyki opisowe: średnia, mediana, minimum, maksimum, kwartyle, odchylenie standardowe
- filtrowanie i grupowanie danych (dplyr)
- funkcje eksploracyjne (skimr, summary()),
- konwersja i czyszczenie danych (tidyr, na.omit, as.numeric)

2 Kod przygotowujący dane do analizy:

```
#wczytywanie danych
dane <- read.csv(file="/Users/kowalski/Desktop/WA_Fn-UseC_-Telco-Customer-Churn.csv",
                 stringsAsFactors = FALSE)

#zmiana typów danych
dane <- dane %>%
  mutate_if(is.character, as.factor)

dane <- dane %>%
  mutate_if(~ is.character(.) & !is.factor(.), ~ as.numeric(as.character(.)))

dane$SeniorCitizen <- ifelse(dane$SeniorCitizen == 1, "Yes", "No")

# nowa zmienna dla danych bez ID klienta poniewaz
# jest to nie potrzeba kolumna w analizie
dane_bez_id <- dane[, !(names(dane) %in% c("customerID"))]
```

Tabela 1: Podstawowe wskaźniki sumaryczne

Zmienna_statystyka	Wartość
tenure_Min	1.00
tenure_Max	72.00
tenure_Średnia	32.42
tenure_Mediana	29.00
tenure_SD	24.55
tenure_IQR	46.00
MonthlyCharges_Min	18.25
MonthlyCharges_Max	118.75
MonthlyCharges_Średnia	64.80
MonthlyCharges_Mediana	70.35
MonthlyCharges_SD	30.09
MonthlyCharges_IQR	54.27
TotalCharges_Min	18.80
TotalCharges_Max	8684.80
TotalCharges_Średnia	2283.30
TotalCharges_Mediana	1397.47
TotalCharges_SD	2266.77
TotalCharges_IQR	3393.29

```
# Usuwamy osoby z bazy ktore maja tenur = 0 poniewaz
# jest ich 11(maly procent z bazy wszystkich osob z bazy)
dane_bez_id <- dane_bez_id %>%
  filter(tenure != 0)
```

3 Wyniki dla jednej zmiennej :

.

.


3.1 Podstawowe wskaźniki sumaryczne:

.


.

3.2 Podstawowe wykresy dla jednej zmiennej :

Zmienne jakościowe:




Page 1



Page 2

Zmienne liczbowe:




3.3 Wykresy dla par zmiennych:

```
zmienne_ilosciowe <- names(dane)[sapply(dane, is.numeric)]


for (i in 1:(length(zmienne_ilosciowe)-1)) {
  for (j in (i+1):length(zmienne_ilosciowe)) {
    zm1 <- zmienne_ilosciowe[i]
    zm2 <- zmienne_ilosciowe[j]

    print(
      ggplot(dane, aes_string(x = zm1, y = zm2)) +
        geom_point(alpha = 0.5, color = "steelblue") +
        geom_smooth(method = "lm", se = FALSE, color = "red") +
        labs(title = paste("Zaleznosc:", zm1, "vs", zm2),
              x = zm1, y = zm2)
    )
  }
}
```


Zależność: tenure vs MonthlyCharges



Zależność: tenure vs TotalCharges



Zależność: MonthlyCharges vs TotalCharges



3.3.1 Analiza zależności między zmiennymi ciągłymi

Na podstawie wykresów rozrzutu dla par zmiennych ilościowych można zauważyć, że:

- **TotalCharges** i **tenure** są ze sobą silnie skorelowane liniowo – im dłużej klient korzysta z usług, tym wyższe łączne opłaty. Zależność ta ma charakter niemal liniowy, co potwierdza dobrze dopasowana czerwona linia regresji.
- Zmienna **MonthlyCharges** ma słabszy związek zarówno z **tenure**, jak i **TotalCharges**. W przypadku MonthlyCharges i tenure nie obserwuje się wyraźnej zależności liniowej – dane są rozproszone, a linia trendu przebiega niemal poziomo.
- Z kolei dla **MonthlyCharges** i **TotalCharges** widać umiarkowaną zależność, ale z dużym rozrzutem – co oznacza, że klienci o podobnych miesięcznych opłatach mogą mieć bardzo różne sumy łącznych opłat w zależności od długości współpracy.

Podsumowując, najbardziej istotna i liniowa zależność występuje pomiędzy TotalCharges a tenure, co jest logiczne, ponieważ im dłużej klient korzysta z usług, tym więcej zapłacił łącznie. Pozostałe pary zmiennych wykazują co najwyżej słabe lub nieliniowe zależności.

3.4 Zakres możliwych wartości dla zmiennych ilościowych:

Na podstawie funkcji range() ustalono zakresy zmiennych ilościowych:

- Zakres zmiennej **Tenure** to: 1, 72
- Zakres zmiennej **MonthlyCharges** to : 18.25, 118.75

- Zakres zmiennej **TotalCharges** to : 18.8, 8684.8

Oznacza to, że klienci mogli korzystać z usług firmy od jednego miesiąca do sześciu lat, a miesięczne opłaty oraz łączne koszty wykazują dużą rozpiętość.

3.5 Zmienne jakościowe:

```
## [1] 2266.77 30.09 24.55
```

Odchylenie standardowe dla poszczególnych zmiennych:

- **Tenure** to 24.5452597
- **MonthlyChargers** to 30.0859739
- **TotalChargers** to 2266.7713619

Największą zmienność wykazuje **TotalCharges** — co jest zgodne z intuicją, ponieważ to wartość skumulowana w czasie i zależna zarówno od stażu, jak i wysokości miesięcznej opłaty.

3.6 Czy zmienne mają rozkład symetryczny?

Na podstawie wcześniejszych wykresów (histogramów, boxplotów) można zauważyć:

- **tenure** – rozkład asymetryczny prawostronny (więcej klientów z krótkim stażem),
- **MonthlyCharges** – rozkład raczej zbliżony do symetrycznego, ale z lekką tendencją do prawej strony,
- **TotalCharges** – rozkład wyraźnie prawoskośny (większość klientów nie zapłaciła dużej sumy).

Zatem nie wszystkie zmienne ilościowe mają rozkład symetryczny.

3.7 Zmienne jakościowe — częstość występowania

```
##
## No Yes
## 5163 1869

##
## No Yes
## 0.734215 0.265785
```

Wyniki:

- **No** (klienci, którzy pozostali): około 73.4%
- **Yes** (klienci, którzy odeszli): około 26.6%

Oznacza to, że zdecydowana większość klientów pozostaje przy usługach firmy, a tylko około 1 na 4 klientów rezygnuje.

Tabela 2: Podstawowe wskaźniki sumaryczne dla Grupy 1

Zmienna_statystyka	Wartość
tenure_Min	1.00
tenure_Max	72.00
tenure_Średnia	17.98
tenure_Mediana	10.00
tenure_SD	19.53
tenure_IQR	27.00
MonthlyCharges_Min	18.85
MonthlyCharges_Max	118.35
MonthlyCharges_Średnia	74.44
MonthlyCharges_Mediana	79.65
MonthlyCharges_SD	24.67
MonthlyCharges_IQR	38.05
TotalCharges_Min	18.85
TotalCharges_Max	8684.80
TotalCharges_Średnia	1531.80
TotalCharges_Mediana	703.55
TotalCharges_SD	1890.82
TotalCharges_IQR	2196.80

4 Wyniki z podziałem na grupy:

Kod kotry dzieli na grupy:

- **Grupa 1** – klienci, którzy zrezygnowali z usług (Churn == “Yes”). Jest ich 1869.
- **Grupa 2** – klienci, którzy pozostali lojalni (Churn == “No”). Jest ich 5163


Dla każdej z grup wyznaczono statystyki opisowe oraz rozkłady zmiennych jakościowych i ilościowych. Wykorzystano funkcje `summary()`, `plot_bar()` i `plot_histogram()` z pakietu `DataExplorer`.

4.1 Analiza Grupy 1:


4.1.1 Wskazniki sumaryczne:

4.1.2 Podstawowe wykresy:

Dla zmiennych jakościowych:




Page 1



Page 2

Dla zmiennych liczbowych:



4.2 Analiza Grupy 2:


4.2.1 Wskazniki sumaryczne:


4.2.2 Podstawowe wykresy:

Dla zmiennych jakościowych:

Tabela 3: Podstawowe wskaźniki sumaryczne dla Grupy 2


Zmienna_statystyka	Wartość
tenure_Min	1.00
tenure_Max	72.00
tenure_Średnia	37.65
tenure_Mediana	38.00
tenure_SD	24.08
tenure_IQR	46.00
MonthlyCharges_Min	18.25
MonthlyCharges_Max	118.75
MonthlyCharges_Średnia	61.31
MonthlyCharges_Mediana	64.45
MonthlyCharges_SD	31.09
MonthlyCharges_IQR	63.37
TotalCharges_Min	18.80
TotalCharges_Max	8672.45
TotalCharges_Średnia	2555.34
TotalCharges_Mediana	1683.60
TotalCharges_SD	2329.46
TotalCharges_IQR	3686.30





Page 2

Dla zmiennych liczbowych:



4.3 Analiza obu grup:

Analizując wizualizacje i średnie wartości zmiennych, można zauważyć, że niektóre cechy różnicują grupy wyraźniej niż inne:

- **Typ umowy** (Contract): klienci z umowami miesięcznymi znacznie częściej rezygnują niż ci, którzy mają umowę na 1 lub 2 lata.
- **Usługi dodatkowe** (OnlineSecurity, OnlineBackup, StreamingTV, StreamingMovies): osoby korzystające z tych usług rzadziej rezygnują. Widoczna różnica w częstościach między grupami.
- **Długość korzystania** (tenure): krótszy staż mocno koreluje z większym prawdopodobieństwem odejścia.
- **Opłaty miesięczne** (MonthlyCharges): klienci płacący więcej miesięcznie częściej odchodzą.

Zmienna InternetService również wykazuje zróżnicowanie – osoby korzystające z usług „Fiber optic” częściej rezygnują niż ci z „DSL” lub „No internet service”.

5 Podsuwanie:

5.1 Wnioski z przeprowadzonych analiz:

Analiza danych pozwoliła na dokładne poznanie struktury zbioru oraz zróżnicowania klientów firmy telekomunikacyjnej. Dane zostały poprawnie przygotowane i oczyszczone z błędnych wartości oraz identyfikatorów. Następnie wykonano eksplorację zmiennych jakościowych i ilościowych, zarówno dla całej populacji, jak i w podziale na grupy Churn.

Zmienna Churn okazała się silnie powiązana z takimi cechami jak:

- **typ umowy** (Contract),
- **długość współpracy** (tenure),
- **miesięczne opłaty** (MonthlyCharges)
- **wykorzystywane usługi dodatkowe** (np. OnlineSecurity, StreamingTV).

5.2 Co mówią dane o klientach firmy?

Zdecydowana większość klientów (ok. 73.4%) pozostaje przy usługach firmy, co wskazuje na ogólnie dobrą retencję. Klienci firmy najczęściej korzystają z internetu światłowodowego (Fiber optic), a także usług takich jak telewizja (StreamingTV) i płatności elektroniczne (Electronic check).

Klienci lojalni zazwyczaj mają **dłuższy staż, niższe opłaty miesięczne** i częściej wybierają **umowy długoterminowe**.

5.3 Co charakteryzuje klientów, którzy odchodzą?

Klienci, którzy rezygnują z usług:

- posiadają umowy na czas nieokreślony (miesięczne),
- mają niski staż (niski tenure),
- ponoszą wyższe opłaty miesięczne,
- rzadziej korzystają z usług zabezpieczających (OnlineSecurity, TechSupport).

5.4 Co firma może z tym zrobić?

Aby przeciwdziałać odchodzeniu klientów, firma powinna:

- zachęcać do podpisywania umów długoterminowych (np. zniżkami),
- monitorować klientów w pierwszych miesiącach korzystania i aktywnie wspierać ich onboarding,
- oferować pakiety lojalnościowe z usługami dodatkowymi (np. bezpieczeństwo online, wsparcie techniczne),
- segmentować klientów według ryzyka rezygnacji i kierować działania retencyjne do odpowiednich grup.