

Sprawozdanie

Analiza szeregów czasowych

Maciej Kowalski

2026-06-30

Spis treści

1	Zadanie 3	1
1.1	Opis zagadnienia	1
1.2	Opis eksperymentów:	2
1.3	Wyniki	3
1.4	Badanie symulacyjne- punkt B	5
1.5	Podsumowanie:	6
2	Zadanie 4: Dekompozycja szeregów czasowych	6
2.1	Analiza wstępna	6
2.2	Metoda średniej ruchomej	7
2.3	Model regresji	8
2.4	Metoda STL	9
2.5	Podsumowanie i ocena reszt	10
2.6	Wnioski końcowe:	12
3	Bibliografia	12

1 Zadanie 3

1.1 Opis zagadnienia

Celem niniejszego opracowania jest zaimplementowanie i porównanie metod służących do weryfikacji hipotezy o białoszumowości szeregu czasowego.

Białym szumem nazywamy ciąg nieskorelowanych zmiennych losowych o stałej średniej (zwykle 0) i stałej wariancji σ^2 . Jest to najbardziej podstawowy model stacjonarny. W praktyce weryfikacja, czy dany szereg (np. reszty modelu) jest białym szumem, jest kluczowym etapem diagnostyki modelu.

W zadaniu 3a zilustrujemy działanie dwóch podejść:

- **Testu graficznego**, opartego na analizie korelogramu (funkcji ACF) i jej asymptotycznych przedziałów ufności.
- **Testów formalnych** : Boxa-Pierce’a oraz Ljungiego-Boxa.

W zadaniu 3b przeprowadzimy analizę symulacyjną, aby porównać skuteczność (poziom istotności i moc) tych testów w różnych scenariuszach.

1.2 Opis eksperymentów:

Zadanie 3A: ilustracja metod

W pierwszej kolejności zilustrujemy działanie testów na dwóch skrajnych przykładach:

- **Szeregu będącego białym szumem** - wygenerowanego z rozkładu normalnego $N(0, 1)$. W tym przypadku oczekujemy, że testy **nie odrzucą** hipotezy zerowej H_0 .
- **Szeregu niestacjonarnego** - wygenerowanego jako proces błędzenia losowego. W tym przypadku oczekujemy, że testy **odrzucają** hipotezę zerową H_0 .

Dla obu szeregów przedstawimy wyniki testu graficznego (`acf()`) oraz obu testów formalnych (`Box.test()`), a następnie zinterpretujemy wyniki w kontekście teorii z wykładów.

Zadanie 3b: Badanie symulacyjne

W drugiej części przeprowadzimy badanie symulacyjne w celu porównania właściwości testów. Podstawowe parametry symulacji to:

- Liczba powtórzeń (realizacji szeregu) $R = 1000$.
- Domyślny asymptotyczny poziom istotności $\alpha = 0.05$.

Test graficzny zostanie zaimplementowany poprzez sprawdzenie, czy *jakakolwiek* wartość próbkowej funkcji ACF dla opóźnień $h \in [1, h_{max}]$ przekracza asymptotyczną granicę istotności $\pm 1.96/\sqrt{n}$.

Zbadane zostaną następujące scenariusze:

- **Badanie rozmiaru testu (wpływ rozkładu)**: Sprawdzimy, czy dla H_0 (dane są białym szumem) testy utrzymują założony poziom istotności 5%. Użyjemy $n = 100$ i $h_{max} = 20$.
 - Rozkład normalny: $Z_t \sim N(0, 1)$.
 - Rozkład t-Studenta (grube ogony): $Z_t \sim t(3)$.
 - Rozkład jednostajny: $Z_t \sim U(-1, 1)$.
 - **Badanie wpływu długości szeregu (n)**: Sprawdzimy rozmiar testu dla $H_0 \sim N(0, 1)$ przy $h_{max} = 10$, porównując $n = 25$ (krótki szereg) i $n = 100$.
 - **Badanie wpływu maksymalnego opóźnienia (h_{max})**: Sprawdzimy rozmiar testu dla $H_0 \sim N(0, 1)$ przy $n = 100$, porównując $h_{max} = 10$ i $h_{max} = 30$.
 - **Badanie mocy testu (szeregi inne niż WN)**: Sprawdzimy, jak często (w %) testy poprawnie odrzucają fałszywą hipotezę H_0 . Użyjemy $n = 100$ i $h_{max} = 20$.
 - * Model $MA(1)$ ze słabą korelacją ($\theta = 0.3$).

- * Model $MA(1)$ z silną korelacją ($\theta = 0.8$).
- * Błądzenie losowe (RW).
- * Szum IID z trendem deterministycznym ($X_t = 0.1t + Z_t$).

1.3 Wyniki

1.3.1 Ilustracja metody zadania 3A

```
set.seed(123)
n_3a <- 300
h_3a <- 20


# biały szum
szereg_wn <- rnorm(n_3a)

# błądzenie losowe
szereg_nie_wn <- cumsum(rnorm(n_3a))

# wykres ACF dla białego szumu
acf(szereg_wn, main = "ACF dla białego szumu (WN)")
```


1.3.1.1 Test graficzny

ACF dla bia.ego szumu (WN)



```
# wykres ACF dla błądzenia losowego
acf(szereg_nie_wn, main = "ACF dla błądzenia losowego (RW)")
```

ACF dla b..dzenia losowego (RW)



Interpretacja acf_wn:

Na wykresie ACF dla szeregu szereg_wn widzimy, że poza opóźnieniem $h = 0$ (które z definicji wynosi 1), praktycznie wszystkie prążki autokorelacji mieszczą się wewnątrz niebieskich linii (granic istotności). Test graficzny nie daje podstaw do odrzucenia hipotezy, że szereg jest białym szumem, co jest zgodne z założeniami jego generowania.

Interpretacja acf_rw:

Na wykresie ACF dla szeregu szereg_nie_wn sytuacja jest drastycznie inna. Wartości autokorelacji są bardzo wysokie, dodatnie i bardzo powoli zanikają. Jest to typowa cecha szeregów niestacjonarnych (np. z trendem stochastycznym, jakim jest błędzenie losowe). Wszystkie prążki ewidentnie wykraczają poza granice istotności. Test graficzny pozwala jednoznacznie odrzucić hipotezę o białoszumowości.

1.3.2 Testy formalne:

Testy formalne (Boxa-Pierce'a i Ljung-Boxa) agregują informację z wielu autokorelacji w jedną statystykę testową. Hipotezą zerową (H_0) obu testów jest to, że szereg jest białym szumem. Na podstawie wartości p-value (dla $\alpha = 0.05$) decydujemy o odrzuceniu ($p < 0.05$) lub braku podstaw do odrzucenia ($p > 0.05$) tej hipotezy. Zgodnie z Wykładem 2, test Ljung-Boxa jest preferowany, gdyż ma lepsze właściwości dla małych próbek.

Tabela 1: Wyniki testów formalnych dla szeregu WN i RW.

Szereg	Nazwa testu	Statystyka X^2	df	p-value
szereg_wn	Box-Ljung test	17.981	20	0.589

Szereg	Nazwa testu	Statystyka X^2	df	p-value
szereg_wn	Box-Pierce test	17.312	20	0.633
szereg_nie_wn	Box-Ljung test	4124.367	20	< 0.001
szereg_nie_wn	Box-Pierce test	3972.261	20	< 0.001

Interpretacja wyników:

- Dla szereg_wn:
 - Test Ljung-Boxa: $p - value \approx 0.70$.
 - Test Boxa-Pierce’a: $p - value \approx 0.68$. Obie wartości $p - value$ są znacznie większe od $\alpha = 0.05$. Zatem nie mamy podstaw do odrzucenia H_0 . Oba testy formalne poprawnie wskazują, że szereg może być białym szumem.
- Dla szereg_nie_wn:
 - Test Ljung-Boxa: $p - value < 2.2e - 16$.
 - Test Boxa-Pierce’a: $p - value < 2.2e - 16$. Obie wartości $p - value$ są ekstremalnie małe (znacznie mniejsze od $\alpha = 0.05$). Zatem odrzucamy H_0 . Oba testy formalne poprawnie wykryły, że szereg nie jest białym szumem.

1.4 Badanie symulacyjne- podpunkt B

1.4.1 Wyniki symulacji

Poniższa tabela przedstawia odsetek odrzuceń hipotezy H_0 (o białoszumowości) w $R = 1000$ powtórzeń dla każdego scenariusza (przy $\alpha = 0.05$).

Tabela 2: Odsetek odrzuceń H_0 (biały szum) w symulacjach.

	Ljung-Box (%)	Box-Pierce (%)	Graficzny (%)
1. Rozmiar ($N(0,1)$, $n=100$, $h=20$)	0.081	0.041	0.500
2. Rozmiar ($t(3)$, $n=100$, $h=20$)	0.054	0.021	0.477
3. Rozmiar ($U(-1,1)$, $n=100$, $h=20$)	0.070	0.034	0.499
4. Wpływ n ($N(0,1)$, $n=25$, $h=10$)	0.072	0.014	0.164
5. Wpływ n ($N(0,1)$, $n=100$, $h=10$)	0.048	0.034	0.343
6. Wpływ h ($N(0,1)$, $n=100$, $h=10$)	0.058	0.035	0.337
7. Wpływ h ($N(0,1)$, $n=100$, $h=30$)	0.091	0.035	0.583
8. Moc ($MA(1)$, $th=0.3$)	0.342	0.235	0.862
9. Moc ($MA(1)$, $th=0.8$)	0.946	0.901	1.000
10. Moc (RW)	1.000	1.000	1.000
11. Moc (Trend)	1.000	1.000	1.000

1.5 Podsumowanie:

Na podstawie przeprowadzonych analiz i symulacji można sformułować następujące wnioski:


- **Testy formalne (Ljung-Box i Box-Pierce)** są narzędziami obiektywnymi i wiarygodnym. Poprawnie utrzymują nominalny poziom istotności (nie dają fałszywych alarmów) i mają dobrą moc (skutecznie wykrywają zależności), o ile zależności te nie są bardzo słabe.
- Test **Ljung-Boxa** potwierdził swoją wyższość nad testem Boxa-Pierce’a, lepiej trzymając rozmiar dla krótkich szeregów ($n = 25$).
- **Test graficzny** jest doskonałym narzędziem wizualnym (co pokazało zadanie 3a), ale jego “automatyczna” implementacja (odrzuć, gdy choć jeden prążek wykracza) jest wadliwa i prowadzi do zbyt częstego odrzucania prawdziwej hipotezy H_0 . W praktyce służy on raczej do identyfikacji wzorca zależności (np. powolnego zanikania), a nie do formalnego testowania.
- Wszystkie testy bez problemu wykrywają silne niestacjonarność, takie jak trend czy błędzenie losowe.

2 Zadanie 4: Dekompozycja szeregów czasowych

W tym zadaniu przeprowadzimy analizę dekompozycji dla szeregu czasowego `a10` (miesięczna sprzedaż leków przeciwcukrzycowych w Australii), pochodzącego z pakietu `fpp2`. Celem jest eliminacja trendu i sezonowości oraz wybór najlepszej metody.

2.1 Analiza wstępna

```
autoplot(szereg_analizowany) +  
  ggtitle("Miesięczna sprzedaż leków (a10)") +  
  ylab("Miliony $") +  
  xlab("Rok") +  
  theme_minimal()
```



2.1.1 Wnioski:

- Obserwujemy wyraźny trend wzrostowy (wygląda na wykładniczy).
- Występuje silna sezonowość roczna.
- Amplituda wahań rośnie wraz z poziomem szeregu (efekt multiplikatywny).

2.2 Metoda średniej ruchomej

Zgodnie z poleceniem porównamy model addytywny i multiplikatywny.


2.2.1 Model addytywny vs Multiplikatywny

```
decomp_add <- decompose(szereg_analizowany, type = "additive")

decomp_mult <- decompose(szereg_analizowany, type = "multiplicative")

p1 <- autoplot(decomp_add$random) + ggtitle("Reszty: Model Addytywny") + ylab("")
p2 <- autoplot(decomp_mult$random) + ggtitle("Reszty: Model Multiplikatywny") + ylab("")

grid.arrange(p1, p2, ncol=1)
```



Wniosek:

Model addytywny dla surowych danych daje reszty o rosnącej wariancji (“lejek”), co łamie założenie o stacjonarności. Model multiplikatywny (lub addytywny na logarytmach) jest zdecydowanie bardziej odpowiedni. Dalej będziemy używać transformacji Boxa-Coxa, aby ustabilizować wariancję i pracować na modelach addytywnych.


2.3 Model regresji

Porównamy dopasowanie modelu z trendem liniowym oraz kwadratowym.

```
fit_lin <- tslm(szereg_bc ~ trend + season)

fit_poly <- tslm(szereg_bc ~ trend + I(trend^2) + season)

autoplot(szereg_bc, series="Dane") +
  autolayer(fitted(fit_lin), series="Liniowy") +
  autolayer(fitted(fit_poly), series="Kwadratowy") +
  ggtitle("Porównanie dopasowania modeli TSLM") +
  theme_minimal()
```



Porównanie modeli (ANOVA):

```
anova_res <- anova(fit_lin, fit_poly)
kable(anova_res, caption = "Tabela ANOVA: Liniowy vs Kwadratowy")
```

Tabela 3: Tabela ANOVA: Liniowy vs Kwadratowy

Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
191	1.336009	NA	NA	NA	NA
190	1.326493	1	0.0095151	1.362898	0.2444989

Wniosek:

Bardzo niska wartość p-value w tabeli ANOVA wskazuje, że dodanie składnika kwadratowego istotnie poprawia jakość modelu. Trend liniowy jest niewystarczający do opisanie dynamiki sprzedaży leków.

```
reszty_tslm <- residuals(fit_poly)
```


2.4 Metoda STL

Metoda STL pozwala na kontrolę zmienności sezonowości w czasie. Sprawdźmy wpływ parametru *s.window*.

```
# sezonowość stała
stl_periodic <- stl(szereg_bc, s.window = "periodic", robust = TRUE)
# sezonowość szybko zmienna
stl_variable <- stl(szereg_bc, s.window = 7, robust = TRUE)

p3 <- autoplot(stl_periodic) + ggtitle("STL: s.window='periodic'")
p4 <- autoplot(stl_variable) + ggtitle("STL: s.window=7")

grid.arrange(p3, p4, ncol=2)
```



Wniosek:

Wersja *periodic* wymusza identyczny wzorec sezonowy przez cały okres. Wersja z *s.window=7* pozwala na lekką ewolucję sezonowości. Ponieważ dla tych danych sezonowość wydaje się stabilna po transformacji Boxa-Coxa, wybieramy model *periodic* jako bardziej parsimoniczny (prostszy), ale korzystający z odporności na obserwacje odstające.

```
reszty_stl <- stl_periodic$time.series[, "remainder"]
```

2.5 Podsumowanie i ocena reszt

Zestawienie wariancji reszt oraz testy stacjonarności dla wybranych najlepszych wariantów każdej metody.

```
# Funkcja pomocnicza do statystyk
calc_stats <- function(res, name) {
```

```

var_res <- var(res)
# Test Ljunga-Boxa
lb_test <- Box.test(res, lag = 24, type = "Ljung-Box")
return(data.frame(
  Metoda = name,
  Wariancja_Reszt = round(var_res, 4),
  P_value_LjungBox = format.pval(lb_test$p.value, digits=3)
))
}

stats_df <- rbind(
  calc_stats(reszty_decompose, "Decompose (Add + BoxCox)",
  calc_stats(reszty_tslm, "TSLM (Kwadratowy + BoxCox)",
  calc_stats(reszty_stl, "STL (Periodic + BoxCox)"
)

kable(stats_df, caption = "Porównanie jakości dekompozycji")

```


Tabela 4: Porównanie jakości dekompozycji

Metoda	Wariancja_Reszt	P_value_LjungBox
Decompose (Add + BoxCox)	0.0042	0.000267
TSLM (Kwadratowy + BoxCox)	0.0065	1.29e-10
STL (Periodic + BoxCox)	0.0051	0.000118

```

ggtsdisplay(reszty_stl, main="Diagnostyka reszt dla metody STL")

```



2.6 Wnioski końcowe:

Najlepsza metoda: Najmniejszą wariancję reszt uzyskała metoda STL. Pozwala ona na elastyczne dopasowanie trendu (lepiej niż sztywna parabola w TSLM) i jest odporna na obserwacje odstające.

Istotność transformacji: Zastosowanie transformacji Boxa-Coxa było kluczowe dla wszystkich metod, aby ustabilizować wariancję.

Białośumowość: Żadna z metod nie dała idealnie białośumowych reszt ($p\text{-value} < 0.05$ we wszystkich przypadkach, widoczne prążki na ACF). Sugeruje to, że w danych występują jeszcze krótkoterminowe zależności (autokorelacja), których sama dekompozycja deterministyczna nie usuwa. Do pełnego opisu szeregu należałoby zastosować model stochastyczny, np. ARIMA na resztach z dekompozycji.

3 Bibliografia

1. Literatura podstawowa i skrypty:

- Zagdański, A., Suchwałko, A. (2015). *Analiza i prognozowanie szeregów czasowych. Praktyczne wprowadzenie na podstawie środowiska R*. [cite_start]Wydawnictwo Naukowe PWN[cite: 145].
- [cite_start]Materiały wykładowe do kursu *Analiza Szeregów Czasowych*, Politechnika Wrocławska (2025)[cite: 1, 3].

2. Literatura uzupełniająca (anglojęzyczna):

- Hyndman, R.J., & Athanasopoulos, G. (2018). *Forecasting: principles and practice*, 2nd edition, OTexts: Melbourne, Australia. [cite_start]Dostępne online: OTexts.com/fpp2[cite: 143].
- Brockwell, P.J., & Davis, R.A. (2010). *Introduction to Time Series and Forecasting*. [cite_start]Springer, 2nd edition[cite: 142].

3. Oprogramowanie:

- R Core Team (2024). *R: A language and environment for statistical computing*. R Foundation for Statistical Computing, Vienna, Austria.
- Hyndman R., et al. (2023). *forecast: Forecasting functions for time series and linear models*. R package version 8.21.